

B 题—新能源日前电价预测

摘要

本文针对新能源参与的电力市场日前电价预测问题，提出了基于多源数据融合与 XGBoost-LSTM 双模型对比的系统解决方案。

针对问题一：本问是数据分析问题，需对多源异构数据进行预处理与描述性分析。首先，对六个附件数据（进行时间对齐，统一重采样至 15 分钟粒度。接着，采用线性插值填补气象变量和光伏发电的缺失值，对光伏夜间负值进行截断处理。然后，计算各变量的描述性统计量，并对各变量间的相关性进行分析。结果讨论显示，合并后数据集共 7393 条记录，日前电价均值为 236.01 元/MWh、标准差为 217.65 元/MWh，电价分布呈明显右偏特征，**变异系数达 0.92**。

针对问题二：本问是统计挖掘问题，需分析 1 至 4 月极端电价触及频次及开停状态与电价偏差的关系。首先，分别统计日前和实时电价触及地板价（ ≤ 41 元/MWh）和天花板价（ ≥ 999 元/MWh）的频次。接着，按月份、小时和星期三维度交叉分析时间分布规律。然后，通过 t 检验和 Mann-Whitney U 检验判断开停状态对电价偏差影响的显著性。结果讨论显示，**地板价触及率高达 46% 以上**，天花板价触及率仅 1.5% 至 2.3%，4 月地板价触及率高达 65%，开停状态对电价偏差影响不显著（ $p=0.58$ ）。

针对问题三：本问是归因分析问题，需量化气象因素及变电站状态对实时电价波动的影响。首先，以电价一阶差分绝对值作为波动指标。接着，采用 Pearson 相关系数、Spearman 相关系数和互信息三种方法进行多维度相关性分析。然后，利用随机森林模型提取特征重要性，并通过 VIF 检验多重共线性。最后，按负荷方向分组分析电价波动差异。结果讨论显示，**负荷、光照强度和光伏发电为电价波动的三大核心因素**，综合得分分别为 0.65、0.60 和 0.52，上网与下网状态下电价波动差异极显著（ $p \approx 0$ ）。

针对问题四：本问是预测建模问题，需构建两种不同原理的电价预测模型并对比。首先，构造滞后特征、滚动统计特征和时间编码特征共 38 维。接着，分别训练 XGBoost 梯度提升树模型和 LSTM 长短期记忆网络模型。然后，在测试集上从 MAE、RMSE、MAPE 和 R^2 四个维度进行对比评估。结果讨论显示，**XGBoost 模型以 MAE=43.23、RMSE=85.04、 $R^2=0.8290$ 的综合表现优于 LSTM**，被选为最优预测模型。

针对问题五：本问是预测应用问题，需基于最优模型预测 4 月 15 日 96 个时间点的日前电价。基于 XGBoost 模型，严格遵循因果约束（仅使用 4 月 14 日及之前已知数据），采用递推预测策略逐一生成 96 个预测值。预测结果显示，**4 月 15 日日前电价均值为 108.38 元/MWh，波动区间为 53.02 至 195.62 元/MWh**，呈现早晚双峰、午间低谷的典型日内模式。

关键词： 新能源日前电价；XGBoost；LSTM；电价波动归因；极端价格分析；时序预测

一、引言

1.1 问题背景

电力市场化发展已成为全球能源体制建设的必然趋势，中国自 2015 年启动新一轮电力体制改革以来，现货市场建设不断提速。其中，日前市场作为电力现货交易的主要渠道，通过集中竞价方式确定次日的电力交易安排和电价水平，在资源优化配置中起着核心作用。随着风电、光伏等新能源的大规模并网，电力供给侧的不确定性显著增加，新能源发电固有的随机性与波动性叠加极低的边际发电成本，使得日前市场电价的波动变得相当剧烈，极大地增加了预测的复杂度和难度。

对发电企业而言，准确的电价预测是优化报价策略、规避市场风险的核心前提；对用电企业而言，电价预测有助于合理控制采购成本、制定用电计划；对市场监管机构而言，电价预测为维护市场稳定、防范价格异常波动提供了决策支撑。因此，如何在 `energy` 参与的复杂电力市场环境下，利用大数据技术从多源异构数据中挖掘电价形成的内在规律，有效提高电价预测精度，已成为当前学术界与工业界亟需解决的关键问题。

本题提供了 2025 年上半年多维度电力市场数据，涵盖电价数据（实时电价和日前电价，每 15 分钟一条）、气象数据（温度、风速、风向、湿度、降雨量、光照强度、气压七类环境指标）、变电站功率数据（高压侧潮流变化）以及新能源发电数据（风能与光伏实际发电量）。电价的形成不仅受供需关系影响，还与电价交易的开停状态、气象条件以及变电站的潮流方向紧密相关。本文旨在深入分析电价与各要素之间的耦合规律，利用多种大数据建模方法，对日前电价进行精准预测。

1.2 问题重述

问题一：根据附件提供的全部数据，进行数据预处理（时间对齐、缺失值填补、异常值处理、多源数据融合），并对预处理后的数据进行系统的描述性统计分析。

问题二：统计 1 月至 4 月期间，实时电价与日前电价触及地板价（40 元/MWh）和天花板价（1000 元/MWh）的频次及其时间分布规律（按月、按时、按星期），分析电价交易开停状态与两种电价偏差之间的内在联系及规律。

问题三：选择合适的大数据分析方法，挖掘并量化气象因素（温度、风速、风向、湿度、降雨量、光照强度、气压）及变电站工作状态（高压侧负荷流向）对实时电价波动的影响程度，给出影响因素的定量排序。

问题四：基于实时电价数据和问题三的分析结果，分别构建两种不同原理的电价预测模型（XGBoost 与 LSTM），对模型进行有效性检验，从预测精度和稳定性两个维度进行对比，选出最优模型。

问题五：依据问题四中选出的最优预测模型，预测 2025 年 4 月 15 日 00:15 至 4 月 16 日 00:00 全时段（共 96 个时间点）的日前电价，并分析预测结果的日内分布特征。

二、总体分析

本题围绕新能源参与电力市场环境下的日前电价预测问题，构建了从数据预处理、极端价格分析、多因素归因、双模型对比到日前预测的完整五步研究框架。

针对问题一，本文对六个附件数据源进行了系统性预处理，包括不同时间粒度的统一对齐、缺失值线性插值填补、异常值截断处理以及多源数据的内连接合并，最终形成了 7393 条 15 分钟粒度的统一数据集，并在此基础上完成了全面的描述性统计和可视化分析。针对问题二，基于预处理数据，对 1 至 4 月期间日前与实时电价的极端价格（地板价和天花板价）触及频次进行了多维度交叉统计，并利用统计检验方法分析了开停状态对电价偏差的影响。针对问题三，本文构建了多维度影响因素分析框架，综合运用 Pearson 相关系数、Spearman 相关系数、互信息和随机森林特征重要性四种方法，量化了气象因素和变电站负荷方向对实时电价波动的贡献度。针对问题四，基于问题三筛选出的重要特征，分别构建了 XGBoost 梯度提升树模型和 LSTM 长短期记忆网络模型，通过时间序列交叉验证和多项评估指标对比，选出了最优预测模型。针对问题五，利用最优模型 XGBoost，严格遵循因果约束条件，对 4 月 15 日 96 个时间点的日前电价进行了递推预测。

以上五个问题具有清晰的递进逻辑：问题一为全题奠定数据基础，问题二从极端价格事件切入揭示市场基本特征，问题三为预测建模提供特征选择的定量依据，问题四在对比中确定最优建模方案，问题五将前四问的成果综合应用于实际预测任务，形成了完整的电价预测研究闭环。

三、模型假设

为简化问题并确保模型的合理性和可操作性，本文做出以下假设：

- **假设一：**电价数据的生成过程满足平稳性假设，即历史电价与未来电价之间存在可利用的统计规律，使得基于历史数据的预测模型具有实用价值。
- **假设二：**气象数据（温度、风速、风向等）在空间上具有一致性，即靖边地区的气象观测数据能够有效代表该区域电力市场的整体气象条件。
- **假设三：**发电数据和负荷数据准确反映了实际的电力生产与消费情况，测量误差在可接受范围内，不影响建模分析的可靠性。
- **假设四：**日前电价市场交易机制在研究时段内保持稳定，不存在因政策调整或市场规则变更导致的电价形成机制突变。
- **假设五：**各影响因素对电价的作用满足可分离性假设，即存在一个统计模型能够以可接受的精度从历史数据中学习各因素与电价之间的映射关系。

四、符号说明

本文使用的主要符号及其含义如表1所示。

表 1 符号说明

符号	说明
$P_{DA}(t)$	t 时刻的日前电价（元/MWh）
$P_{RT}(t)$	t 时刻的实时电价（元/MWh）
$\Delta P(t)$	t 时刻的电价波动量，即 $ P_{RT}(t) - P_{RT}(t - 1) $ （元/MWh）
$W(t)$	t 时刻的风能发电功率（MW）
$S(t)$	t 时刻的光伏发电功率（MW）
$L(t)$	t 时刻的高压侧负荷（MW）
$T(t)$	t 时刻的温度（°C）
$V(t)$	t 时刻的风速（m/s）
$D(t)$	t 时刻的风向（°）
$H(t)$	t 时刻的湿度（%）
$R(t)$	t 时刻的降雨量（mm）
$I(t)$	t 时刻的光照强度（W/m ² ）
$B(t)$	t 时刻的气压（hPa）
$O(t)$	t 时刻的开停状态（1 为开，0 为停）
r	Pearson 或 Spearman 相关系数
I_{MI}	互信息得分
Imp_f	随机森林特征 f 的重要性得分
VIF	方差膨胀因子
MAE	平均绝对误差
RMSE	均方根误差
MAPE	平均绝对百分比误差
R^2	决定系数
k	滞后阶数
τ	模型参数
ϵ	预测残差
X_t	t 时刻的特征向量
y_t	t 时刻的预测目标值

五、模型的建立与求解

5.1 问题一的模型的建立和求解

5.1.1 具体分析

问题一要求对附件提供的全部数据进行预处理并进行描述性分析，属于典型的数据预处理与探索性数据分析问题。本问采用基于时间对齐的多源数据融合方法，结合线性插值和截断处理等技术完成数据清洗，并通过描述性统计和可视化手段进行全面分析。

首先对六个附件数据源（日前电价 9888 条、实时电价 9888 条、风能发电 2880 条、光伏发电 2880 条、高压侧负荷 35712 条、气象数据 3181 条）进行逐一加载与结构检查，接着针对三种不同时间粒度（15 分钟、5 分钟、小时）通过重采样统一至 15 分钟标准粒度，然后对气象变量和光伏发电的缺失值采用线性插值填补、对光伏夜间负值进行截断处理，最后通过内连接完成多源数据融合，并计算各变量的描述性统计量和相关性矩阵。具体分析流程如图1所示。




图 1 问题一分析流程图

5.1.2 模型准备

在进行建模之前，需要对原始数据进行系统性的预处理，以确保数据质量和一致性，为后续各问题的求解提供可靠的输入基础。本节将从数据预处理和算法选择两方面进行准备。

原始数据来源于六个独立的 Excel 文件，总计包含超过 6.5 万条原始记录。经检查发现以下关键问题：第一，不同数据源的时间粒度不统一——电价数据为 15 分钟间隔，负荷数据为 5 分钟间隔，发电和气象数据为小时间隔；第二，气象数据中 WIND_DIRECTION、SUNLIGHT_INTENSITY 和 ISOBARIC 三个变量各存在 113 个缺失值，光伏发电数据存在 1 个缺失值；第三，光伏发电数据在夜间存在微小负值（最低为-0.09 MW），属于测量噪声；第四，各数据源的时间范围不完全重叠，电价数据截至 4 月 14 日，而负荷和

气象数据则延续至 5 月。

针对上述问题，按以下步骤进行预处理。第一步，时间对齐：将风能和光伏发电的小时数据通过前向填充重采样至 15 分钟，将负荷的 5 分钟数据取其 3 个采样点的均值重采样至 15 分钟，将气象的小时数据通过前向填充重采样至 15 分钟。第二步，缺失值处理：对气象变量和光伏发电的缺失值采用线性插值方法填补，确保数据的连续性和完整性。第三步，异常值处理：将光伏发电的负值截断为 0，因为夜间光伏发电在物理上不可能为负值。第四步，多源数据融合：以时间戳为键，对六个数据源进行内连接合并，得到统一的数据集。同时，对数据采用 Min-Max 归一化进行无量纲处理，其计算公式为：

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (1)$$

其中， x_{min} 和 x_{max} 分别为变量的最小值和最大值。选择 Min-Max 归一化而非 Z-score 标准化的原因是电价数据存在极端值（地板价 40 元/MWh 和天花板价 1000 元/MWh），Z-score 方法对离群值敏感，而 Min-Max 归一化将数据统一压缩至 [0, 1] 区间，更适合后续的机器学习建模。

预处理后，合并数据集包含 7393 条记录和 23 个维度（含衍生特征），时间范围为 2025 年 1 月 27 日至 4 月 14 日。各核心变量的描述性统计量如表2所示。

表 2 核心变量描述性统计

变量	均值	标准差	最小值	最大值	偏度	变异系数
日前电价	236.01	217.65	40.00	1000.00	1.12	0.92
实时电价	218.29	199.80	40.00	1000.00	1.09	0.92
风能发电	244.12	202.50	0.00	733.46	0.56	0.83
光伏发电	34.01	48.67	0.00	186.95	1.22	1.43
负荷	-32.63	281.77	-657.71	504.83	-0.06	8.64
温度	1.06	7.35	-22.00	21.00	-0.04	6.95
风速	3.57	2.34	0.00	13.50	1.10	0.65
湿度	34.27	20.78	5.00	100.00	1.24	0.61
光照强度	249.45	324.90	0.00	1045.52	0.91	1.30
气压	864.32	5.14	842.73	877.23	-0.45	0.006

由表2可知，日前电价与实时电价的均值和标准差较为接近，但均存在显著的正偏态分布（偏度大于 1），说明电价在多数时段处于较低水平，少数时段出现极端高价。光伏发电的变异系数高达 1.43，体现了光伏出力的强间歇性。负荷的标准差远大于均值（变异系数 8.64），反映出高压侧潮流方向的频繁切换。

综上所述，数据预处理完成，多源异构数据已被整合为统一的清洁数据集，为后续各问题的建模分析奠定了坚实基础。

5.1.3 模型建立

针对问题一，本节将从描述性统计和数据可视化的角度建立数据分析模型。具体过程如下。

步骤一：描述性统计指标体系的建立

首先，建立覆盖集中趋势、离散程度和分布形态三维度的描述性统计指标体系。设有变量 X ，其样本容量为 N ，各统计指标定义如下。

均值的计算公式为：

$$\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i \quad (2)$$

其中， X_i 为第 i 个样本值， N 为样本容量， $\bar{X}$ 反映数据的集中趋势。

标准差的计算公式为：

$$\sigma_X = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (X_i - \bar{X})^2} \quad (3)$$

其中， σ_X 反映数据的离散程度。

偏度的计算公式为：

$$S_X = \frac{1}{N} \sum_{i=1}^N \left(\frac{X_i - \bar{X}}{\sigma_X} \right)^3 \quad (4)$$

其中， $S_X > 0$ 表示右偏分布， $S_X < 0$ 表示左偏分布， $S_X = 0$ 表示对称分布。

变异系数的计算公式为：

$$CV_X = \frac{\sigma_X}{|\bar{X}| + \varepsilon} \quad (5)$$

其中， ε 为极小正数以避免除零， CV_X 用于比较不同量纲变量的离散程度。

振幅的计算公式为：

$$A_X = X_{max} - X_{min} \quad (6)$$

其中， X_{max} 和 X_{min} 分别为最大值和最小值。

步骤二：相关性分析模型的建立

为进一步分析变量之间的线性关联程度，建立 Pearson 相关系数矩阵。对于两个变量 X 和 Y ，其 Pearson 相关系数为：

$$r_{XY} = \frac{\sum_{i=1}^N (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^N (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^N (Y_i - \bar{Y})^2}} \quad (7)$$

其中， $r_{XY} \in [-1, 1]$ ， $r_{XY} > 0$ 表示正相关， $r_{XY} < 0$ 表示负相关， $|r_{XY}|$ 越接近 1 表示线性相关性越强。

对所有数值变量两两计算式 (6) 定义的相关系数，形成相关性矩阵 R ：

$$R = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1m} \\ r_{21} & 1 & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{m1} & r_{m2} & \cdots & 1 \end{bmatrix} \quad (8)$$

其中， m 为变量个数， r_{ij} 为变量 i 与变量 j 的 **Pearson** 相关系数。

综上所述，本节完成了描述性统计指标体系和相关性分析模型的建立，接下来将基于此对预处理后的数据进行全面分析。

5.1.4 模型求解

基于上述模型，本节利用预处理后的 7393 条数据进行求解。

首先，对各核心变量进行描述性统计分析，结果详见表2。从表中可以看出，电价类变量（日前电价和实时电价）均呈现显著的正偏态（偏度 > 1 ），意味着大多数时段电价处于中低水平，少数极端时段出现高价。变异系数均接近 1，反映了电价的高波动特性。光伏发电的变异系数高达 1.43，体现了光伏出力受天气影响的强间歇性特征。

其次，对核心变量进行了可视化分析。如图2所示，日前电价和实时电价在趋势上高度吻合，但局部存在偏差。日内小时平均电价走势呈明显的周期性波动规律。




图 2 电价时序趋势图（30 天样本）

如图3所示，日前电价和实时电价均呈明显的右偏分布，大量观测值集中在低价区域（40 至 200 元/MWh），高价区分布稀疏但延伸至 1000 元/MWh。




图 3 电价分布直方图

如图4所示，风能日均发电量波动较大，光伏日均发电量呈明显的季节性上升趋势。




图 4 风能和光伏日均发电量时序图

如图5所示，变量之间的相关性热力图显示，实时电价与日前电价之间的相关系数高达 0.95 以上，体现出高度一致性。光伏发电与光照强度之间呈强正相关 ($r \approx 0.85$)，而负荷与电价之间的相关性较弱。




图 5 变量相关性矩阵热力图

如图6所示，高压侧负荷日平均值在零线上下波动，上网（负值）和下网（正值）时段交替出现，反映了变电站功率流向的频繁切换特征。




图 6 高压侧负荷日均时序图

从日内小时平均电价走势（图7）可以观察到典型的双峰结构，早晚高峰时段电价较高，夜间和午间电价相对较低，这一模式与电力负荷的日内变化规律一致。




图 7 日内小时平均电价走势图

综合以上结果，预处理后的数据质量良好，各变量分布合理，变量间的相关性模式与电力市场的物理规律一致。数据已准备就绪，可供后续问题使用。

5.2 问题二的模型的建立和求解

5.2.1 具体分析

问题二要求统计 1 月至 4 月期间实时电价与日前电价触及地板价和天花板价的频次及其时间分布规律，并分析开停状态与两种电价偏差之间的内在联系，属于统计挖掘与假设检验问题。本问采用极端值阈值判定与多维度交叉统计方法进行频次分析，并利用双样本假设检验判断开停状态的影响显著性。

首先基于预处理数据筛选 1 至 4 月时段，设定地板价判定阈值为 41 元/MWh（实际地板价 40 元/MWh 加上 1 元容差）和天花板价判定阈值为 999 元/MWh，接着分别对日前和实时电价标记极端价格触及事件，然后按月份、小时和星期三个维度交叉统计触及频次分布，最后计算开和停两种状态下日前与实时电价的偏差，并通过 t 检验和 Mann-Whitney U 检验判断差异显著性。具体分析流程如图8所示。




图 8 问题二分析流程图

5.2.2 模型准备

该问题本质上是一个统计频次分析与假设检验问题，需要在 1 至 4 月的时间窗口内对日前和实时两种电价的极端价格事件进行系统性的统计，并检验开停状态这一分类变量对电价偏差的影响。

本问题采用的方法体系包括：频次统计方法用于极端价格事件的计数与分布特征提取；交叉分组统计方法用于多维度（月份 × 小时 × 星期）的时间分布挖掘；独立双样本 t 检验用于检验开和停两组电价偏差均值的差异显著性；Mann-Whitney U 检验作为非参数备选方法，在数据不满足正态性假设时提供更稳健的统计推断。 t 检验的统计量定义为：

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (9)$$

其中， $\bar{X}_1$ 和 $\bar{X}_2$ 分别为开和停状态下的样本均值， s_1^2 和 s_2^2 为样本方差， n_1 和 n_2 为样本量。Mann-Whitney U 检验的统计量定义为：

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1 \quad (10)$$

其中， R_1 为第一组样本的秩和。

通过上述方法体系的组合运用，可以在统计意义上严谨地回答极端价格的时间分布规律和开停状态对电价偏差的影响两个核心问题。

5.2.3 模型建立

针对问题二，本节将从极端价格事件统计模型和开停偏差分析模型两方面进行建立。具体过程如下。

步骤一：极端价格事件判定模型

首先，建立二元判定函数以标记每个时间点是否触及极端价格。设 $P_{DA}(t)$ 和 $P_{RT}(t)$ 分别为 t 时刻的日前电价和实时电价，地板价阈值为 $\theta_{floor} = 41$ ，天花板价阈值为 $\theta_{ceiling} = 999$ 。定义地板价触及指示变量为：

$$F_{DA}(t) = \mathbb{I}[P_{DA}(t) \leq \theta_{floor}], \quad F_{RT}(t) = \mathbb{I}[P_{RT}(t) \leq \theta_{floor}] \quad (11)$$

其中， $\mathbb{I}[\cdot]$ 为指示函数，条件成立时取 1，否则取 0。

天花板价触及指示变量为：

$$C_{DA}(t) = \mathbb{I}[P_{DA}(t) \geq \theta_{ceiling}], \quad C_{RT}(t) = \mathbb{I}[P_{RT}(t) \geq \theta_{ceiling}] \quad (12)$$

步骤二：多维度频次统计模型

总触及频次的计算公式为：

$$N_{F,DA} = \sum_t F_{DA}(t), \quad N_{F,RT} = \sum_t F_{RT}(t) \quad (13)$$

$$N_{C,DA} = \sum_t C_{DA}(t), \quad N_{C,RT} = \sum_t C_{RT}(t) \quad (14)$$

对于按月份的交叉统计，定义月份 $m \in \{1, 2, 3, 4\}$ ，各月触及频次为：

$$N_{F,DA}^{(m)} = \sum_{t \in \mathcal{T}_m} F_{DA}(t) \quad (15)$$

其中， $\mathcal{T}_m$ 为属于第 m 月的所有时间点集合。

同理可定义按小时 $h \in \{0, 1, \dots, 23\}$ 和按星期 $w \in \{0, 1, \dots, 6\}$ 的频次统计。

步骤三：开停电价偏差分析模型

日前电价与实时电价的偏差定义为：

$$\Delta P(t) = P_{DA}(t) - P_{RT}(t) \quad (16)$$

绝对偏差定义为：

$$|\Delta P(t)| = |P_{DA}(t) - P_{RT}(t)| \quad (17)$$

对于开状态下的样本集合 $\mathcal{S}_{on} = \{t : O(t) = 1\}$ 和停状态下的样本集合 $\mathcal{S}_{off} = \{t : O(t) = 0\}$ ，分别计算偏差的均值和标准差，并采用式 (1) 和式 (2) 中的 t 检验和 Mann-Whitney U 检验进行假设检验。

综上所述，本节完成了极端价格判定、多维度频次统计和开停偏差分析三个模型的建立，接下来将基于 1 至 4 月的数据进行求解。

5.2.4 模型求解

基于上述模型，本节利用 1 至 4 月共 7393 条数据进行求解。

首先，极端价格频次统计结果如表3所示。日前电价地板价触及 3329 次（占比 45.03%），实时电价地板价触及 3435 次（占比 46.46%），接近半数的时段电价处于地板价附近。日前电价天花板价触及 168 次（2.27%），实时电价天花板价触及 114 次（1.54%），极端高价事件相对稀有。4 月地板价触及率高达 65% 以上，远高于其他月份，表明 4 月电价整体处于低位。

表 3 极端价格触及频次月度统计

月份	日前地板价	日前天花板价	实时地板价	实时天花板价
1 月	201 (41.88%)	12 (2.50%)	175 (36.46%)	45 (9.38%)

表 3 极端价格触及频次月度统计（续）

月份	日前地板价	日前天花板价	实时地板价	实时天花板价
2 月	1037 (38.58%)	80 (2.98%)	1132 (42.11%)	29 (1.08%)
3 月	1276 (42.88%)	64 (2.15%)	1325 (44.52%)	22 (0.74%)
4 月	815 (65.25%)	12 (0.96%)	803 (64.29%)	18 (1.44%)

其次，极端价格的日内分布分析如图9所示。地板价触及集中在上午 9 时至下午 16 时（光伏出力高峰时段），天花板价触及在傍晚至夜间时段（18 时至 23 时）和凌晨时段（0 时至 1 时）更为频繁，这与光伏出力消退后供需紧张的市场规律一致。




图 9 极端价格日内分布图

然后，开停状态与电价偏差的关系分析结果如表4所示。开状态下电价绝对偏差均值为 71.79 元/MWh，停状态下为 75.77 元/MWh，两者在数值上接近。独立双样本 t 检验得到 p 值为 0.58，Mann-Whitney U 检验 p 值为 0.98，均远大于 0.05 的显著性水平，表明开停状态对电价偏差的影响在统计上不显著。

表 4 开停状态电价偏差统计

状态	样本数	绝对偏差均值	绝对偏差标准差
开	7041 (95.24%)	71.79	130.68
停	352 (4.76%)	75.77	134.45

如图10所示，开和停两种状态下的电价偏差箱线图分布高度重叠，进一步验证了开停状态并非影响电价偏差的关键因素。




图 10 开停状态电价偏差箱线图

综合以上结果，地板价在电力市场中极为普遍，尤其在光伏出力较强的午间时段；天花板价虽罕见，但在特定时段（傍晚和凌晨）有聚集出现的趋势；开停状态对日前和实时电价偏差的影响不显著，电价偏差可能主要受其他市场因素驱动。

5.3 问题三的模型的建立和求解

5.3.1 具体分析

问题三要求挖掘并量化气象因素及变电站工作状态对实时电价波动的影响，属于多因素归因分析问题。本问综合运用 Pearson 相关分析、Spearman 秩相关分析、互信息和随机森林特征重要性四种不同原理的方法，从线性和非线性两个维度全面量化各因素对电价波动的贡献度。

首先以相邻时段实时电价的一阶差分绝对值作为电价波动指标，接着分别计算 Pearson 和 Spearman 相关系数以捕捉线性和单调关系，然后利用互信息捕捉非线性依赖关系，再用随机森林模型提取特征重要性排序，最后通过 VIF 检验多重共线性并按负荷方向进行分组对比分析。具体分析流程如图11所示。




图 11 问题三分析流程图

5.3.2 模型准备

该问题本质上是一个多因素归因分析问题，需要在十个候选影响因素（风能发电、光伏发电、负荷、温度、风速、风向、湿度、降雨量、光照强度、气压）中识别对电价波动最具解释力的核心因子。本节的算法选择思路如下。

常用的因素归因方法包括：**Pearson** 相关分析（捕捉线性关系，计算效率高，但对非线性关系不敏感）、**Spearman** 秩相关分析（捕捉单调关系，对异常值鲁棒）、互信息（**MI**，能捕捉任意形式的线性和非线性依赖，但对连续变量的估计需谨慎）、随机森林特征重要性（基于模型的全局归因，能反映特征在预测任务中的实际贡献）以及方差膨胀因子（**VIF**，用于检测特征间的多重共线性）。

从表5的对比可以看出，单一方法各有局限——相关分析只能检测线性或单调关系，互信息对样本量较敏感，随机森林重要性受共线性影响。因此本节采用多方法融合策略：以 **Pearson** 和 **Spearman** 相关分析为基础，互信息作为非线性补充，随机森林重要性作为全局归因核心，**VIF** 作为共线性控制手段，最终通过归一化加权得到综合影响排序。

表 5 因素归因方法对比

方法	线性检测	非线性检测	对异常值鲁棒性	计算效率
Pearson	优	差	差	优
Spearman	良	良	优	良
互信息 (MI)	良	优	中	中
RF 重要性	良	优	优	中

综上所述，本节采用四种方法融合的策略，确保从多个角度全面、可靠地量化各因素对电价波动的影响。

5.3.3 模型建立

针对问题三，本节将从电价波动指标构建、多维度归因分析和综合影响评分三方面建立模型。具体过程如下。

步骤一：电价波动指标的建立

首先，定义实时电价波动量为相邻时段电价的一阶差分的绝对值：

$$\Delta P_{RT}(t) = |P_{RT}(t) - P_{RT}(t - 1)|$$

(18)

其中， $P_{RT}(t)$ 为 t 时刻的实时电价， $\Delta P_{RT}(t)$ 反映了电价在相邻 15 分钟间隔内的变化幅度。

相对波动率定义为：

$$\delta P_{RT}(t) = \frac{\Delta P_{RT}(t)}{P_{RT}(t-1) + \varepsilon} \quad (19)$$

其中， $\varepsilon = 0.01$ 为避免除零的微小常数。

步骤二：多维度相关性分析模型

对于 Pearson 相关系数，其定义为式 (6) 中所述。对于 Spearman 秩相关系数，先将原始数据转换为秩次，再计算秩次间的 Pearson 相关系数：

$$\rho_{XY} = 1 - \frac{6 \sum d_i^2}{N(N^2 - 1)} \quad (20)$$

其中， d_i 为第 i 个样本在 X 和 Y 中的秩次差， N 为样本量。

对于互信息，其定义为联合分布与边缘分布乘积之间的 Kullback-Leibler 散度：

$$I(X; Y) = \sum_{x \in X} \sum_{y \in Y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)} \quad (21)$$

其中， $p(x, y)$ 为联合概率分布， $p(x)$ 和 $p(y)$ 为边缘概率分布。

步骤三：随机森林特征重要性模型

随机森林模型对特征 j 的重要性通过在所有决策树上对基于该特征的分裂所带来的不纯度减少量进行平均来计算：

$$\text{Imp}_j = \frac{1}{T} \sum_{t=1}^T \sum_{n \in \mathcal{N}_t(j)} \Delta I(n) \quad (22)$$

其中， T 为树的数量， $\mathcal{N}_t(j)$ 为第 t 棵树中使用特征 j 进行分裂的节点集合， $\Delta I(n)$ 为节点 n 分裂前后的不纯度减少量。

步骤四：综合影响评分模型

为融合四种方法的分析结果，对各项得分进行 Min-Max 归一化后取等权平均：

$$S_j = \frac{1}{4} \left(\tilde{r}_j^P + \tilde{\rho}_j^S + \tilde{I}_j^{MI} + \tilde{I}_j^{RF} \right) \quad (23)$$

其中， $\tilde{r}_j^P$ 、 $\tilde{\rho}_j^S$ 、 $\tilde{I}_j^{MI}$ 和 $\tilde{I}_j^{RF}$ 分别为归一化后的 Pearson $|r|$ 、Spearman $|\rho|$ 、互信息和随机森林重要性得分。

综上所述，本节完成了从单一相关性到多维度融合归因的全链条模型建立，接下来将基于预处理数据进行求解。

5.3.4 模型求解

基于上述模型，本节利用全部预处理数据进行求解。

首先，Spearman 相关系数分析结果如表6所示。光照强度与电价波动的 Spearman 相关系数绝对值最大（-0.3239），其次是光伏发电（-0.2932）和负荷（+0.2913）。值得

注意的是，光照强度和光伏发电与电价波动均呈负相关，说明光伏出力越大、光照越强时电价波动反而越小；而负荷与电价波动呈正相关，表明电网潮流变化越大电价波动越剧烈。

表 6 各因素与电价波动的 Spearman 相关系数

因素	Spearman ρ	显著性 p 值	方向	与电价波动关系
光照强度	-0.3239	$< 10^{-179}$	负相关	光照越强波动越小
光伏发电	-0.2932	$< 10^{-145}$	负相关	光伏越多波动越小
负荷	+0.2913	$< 10^{-143}$	正相关	负荷越大波动越大
湿度	+0.2018	$< 10^{-68}$	正相关	湿度越大波动越大
温度	-0.1618	$< 10^{-43}$	负相关	温度越高波动越小
风能发电	-0.1289	$< 10^{-28}$	负相关	风能越多波动越小
风速	-0.1281	$< 10^{-27}$	负相关	风速越大波动越小

其次，随机森林特征重要性排序结果如图12所示。负荷以 0.435 的重要性得分遥遥领先，其次是风能发电（0.087）、气压（0.083）和光照强度（0.078），而降雨量（0.003）几乎对电价波动无贡献。VIF 检验结果显示，所有变量的 VIF 值均低于 10，不存在严重的多重共线性问题。




图 12 多因素综合影响排序图

然后，负荷方向分组分析的结果表明，上网（负荷为负）状态下电价波动均值为 23.12 元/MWh，下网（负荷为正）状态下为 39.33 元/MWh，两者差异在统计上极为显著（Mann-Whitney U 检验 $p \approx 0$ ），如图13所示。这一发现说明变电站功率流向是影响电价波动程度的重要因素。




图 13 不同负荷方向电价波动箱线图

综合四种方法的归一化得分，最终的综合影响排序前三名为：负荷（综合得分 0.6488）、光照强度（0.5968）、光伏发电（0.5248）。这三个因素构成了电价波动的核心驱动力，为后续预测建模的特征选择提供了定量依据。

如图14所示，滞后相关性分析显示光照强度在 24 小时滞后处（即前一日同一时刻）相关性最强（ $r = -0.158$ ），表明电价波动存在显著的日周期效应；光伏发电则在即时

(1步滞后)处相关性最强 ($r = -0.127$), 体现了光伏出力的瞬时影响特征。




图 14 关键因素滞后相关性曲线

综合以上结果, 负荷、光照强度和光伏发电是实时电价波动的三大核心影响因素, 三者从不同角度反映了电力市场的供需平衡状态, 为问题四的预测模型特征选择提供了可靠依据。

5.4 问题四的模型的建立和求解

5.4.1 具体分析

问题四要求结合问题三的分析结果, 构建两种不同原理的电价预测模型并进行有效性检验与对比, 属于典型的时序预测建模问题。本问选择 **XGBoost** (梯度提升树, 基于集成学习的树模型) 和 **LSTM** (长短期记忆网络, 基于深度学习的循环神经网络) 作为两种不同原理的预测模型, 从预测精度和稳定性两个维度进行系统对比。

首先基于问题三筛选出的重要特征进行特征工程 (构造滞后特征、滚动统计特征和时间编码特征), 接着将时序数据按时间顺序划分为训练集 (70%)、验证集 (15%) 和测试集 (15%), 然后分别训练和调优 **XGBoost** 和 **LSTM** 两个模型, 最后在测试集上从 **MAE**、**RMSE**、**MAPE** 和 R^2 四个指标进行对比评估。具体分析流程如图15所示。




图 15 问题四分析流程图

5.4.2 模型准备

该问题本质上是一个时序预测建模问题，需要在数千个历史电价观测值的基础上，构建能够准确预测未来电价的数学模型。

本问题选择两种不同原理的方法进行建模对比。XGBoost (eXtreme Gradient Boosting) 是一种基于梯度提升框架的集成树模型，通过迭代地训练弱学习器（决策树）并以梯度方向逐步逼近真实值，其优势在于处理表格型数据时的鲁棒性和高效性。LSTM (Long Short-Term Memory) 是一种专门设计的循环神经网络，通过引入遗忘门、输入门和输出门的门控机制，能够有效地捕捉时间序列中的长期依赖关系，其优势在于对序列数据的建模能力。

从表7的对比可以看出，两种模型在原理上截然不同：XGBoost 将时序问题转化为监督学习问题，通过人工构造的滞后和统计特征来捕获时间依赖；LSTM 则直接以原始序列为输入，利用其内置的记忆机制自动学习时间依赖模式。

表 7 预测模型原理对比

维度	XGBoost	LSTM	对比结论
核心原理	梯度提升树集成	循环神经网络	树模型 vs 深度学习
时序处理	人工构造滞后特征	门控记忆单元	显式 vs 隐式建模
训练方式	逐树迭代优化	反向传播梯度下降	不同优化范式
可解释性	特征重要性可解释	黑箱模型	XGBoost 更可解释
计算效率	高	较低	XGBoost 更高效

综上所述，本节选择 XGBoost 和 LSTM 两种不同原理的模型进行预测对比，既涵盖了传统机器学习和深度学习两大范式，又确保了两种模型在原理上的互补性，为客观对比提供了基础。

5.4.3 模型建立

针对问题四，本节将分别建立 XGBoost 预测模型和 LSTM 预测模型。具体过程如下。

步骤一：特征工程体系的建立

将时序预测转化为监督学习问题，需要构造多维特征向量 X_t 。特征体系包含三类：基础特征（气象、发电、负荷等共 10 维）、时间编码特征（小时、月份、星期的正余弦编码共 6 维）以及历史信息特征（滞后特征和滚动统计特征）。

滞后特征的构造公式为：

$$x_t^{\text{lag},k} = P_{RT}(t - k \cdot \Delta t)$$

(24)

其中, $k \in \{1, 2, 3, 4, 8, 12, 24, 48, 96\}$ 为滞后阶数, $\Delta t = 15$ 分钟。

滚动均值特征的构造公式为:

$$x_t^{\text{roll},w} = \frac{1}{w} \sum_{i=1}^w P_{RT}(t - i \cdot \Delta t) \quad (25)$$

其中, $w \in \{4, 12, 24, 48\}$ 为窗口大小, 分别对应 1 小时、3 小时、6 小时和 12 小时。

滚动标准差特征的构造公式为:

$$x_t^{\text{std},w} = \sqrt{\frac{1}{w-1} \sum_{i=1}^w (P_{RT}(t - i \cdot \Delta t) - x_t^{\text{roll},w})^2} \quad (26)$$

时间正余弦编码的构造公式为:

$$x_t^{\text{hour},\sin} = \sin\left(\frac{2\pi h(t)}{24}\right), \quad x_t^{\text{hour},\cos} = \cos\left(\frac{2\pi h(t)}{24}\right) \quad (27)$$

其中, $h(t) \in \{0, 1, \dots, 23\}$ 为 t 时刻的小时数。这种编码方式保证了 0 时和 23 时在圆环上的连续性。

最终特征向量共 38 维, 构成输入空间 $\mathcal{X} \subset \mathbb{R}^{38}$ 。

步骤二: XGBoost 预测模型的建立

XGBoost 模型的核心思想是通过迭代添加回归树来最小化带有正则化项的损失函数。第 m 轮迭代的预测值为:

$$\hat{y}_i^{(m)} = \hat{y}_i^{(m-1)} + \eta \cdot f_m(X_i) \quad (28)$$

其中, η 为学习率, f_m 为第 m 棵回归树。

XGBoost 的目标函数为:

$$\mathcal{L}^{(m)} = \sum_{i=1}^N l(y_i, \hat{y}_i^{(m-1)} + f_m(X_i)) + \Omega(f_m) \quad (29)$$

其中, l 为损失函数 (采用平方误差), 正则化项 $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$, T 为叶子节点数, w 为叶子权重, γ 和 λ 为正则化参数。

模型的核心超参数设置如表8所示。

表 8 XGBoost 模型超参数设置

参数	含义	取值	选取依据
n_estimators	树的数量	300	平衡拟合与效率
max_depth	树的最大深度	7	防止过拟合
learning_rate	学习率	0.05	小步长稳定收敛

表 8 XGBoost 模型超参数设置（续）

参数	含义	取值	选取依据
subsample	样本采样比例	0.8	增加随机性防过拟合
reg_alpha	L1 正则化系数	0.1	控制模型复杂度
reg_lambda	L2 正则化系数	1.0	平滑叶子权重

步骤三：LSTM 预测模型的建立

LSTM 模型将时间序列数据组织为三维张量 $(N, \text{SEQ_LEN}, d)$ 格式，其中序列长度 $\text{SEQ_LEN} = 96$ （24 小时）， $d = 38$ 为特征维度。LSTM 单元的前向传播公式为：

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (30)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (31)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (32)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (33)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (34)$$

$$h_t = o_t \odot \tanh(C_t) \quad (35)$$

其中， f_t 、 i_t 、 o_t 分别为遗忘门、输入门和输出门， C_t 为细胞状态， h_t 为隐藏状态， σ 为 sigmoid 函数， $\odot$ 表示逐元素乘法。

LSTM 输出后接两层全连接层将隐藏状态映射至标量预测值，损失函数采用 Huber 损失以增强对电价异常值的鲁棒性。

步骤四：模型评估指标体系的建立

预测精度评估采用四项指标。MAE 的定义为：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (36)$$

RMSE 的定义为：

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (37)$$

MAPE 的定义为：

$$\text{MAPE} = \frac{1}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \quad (38)$$

R^2 的定义为：

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (39)$$

综上所述，本节建立了完整的特征工程体系、两种不同原理的预测模型以及多维度的评估指标体系，接下来将基于预处理数据进行训练和对比。

5.4.4 模型求解

基于上述模型，本节利用预处理后的 7297 条数据进行训练和评估。

首先，XGBoost 模型的 5 折时间序列交叉验证结果如表9所示。五折 CV 的 MAE 均值为 54.70，RMSE 均值为 86.19，模型在不同时间段的表现存在一定波动（MAE 标准差 15.09），这与训练初期数据量较少有关。

表 9 XGBoost 5 折交叉验证结果

折次	MAE	RMSE
Fold 1	75.10	116.31
Fold 2	65.30	88.75
Fold 3	50.69	74.02
Fold 4	42.19	75.91
Fold 5	40.21	75.96
均值 ± 标准差	54.70±15.09	86.19±17.83

其次，两个模型在测试集上的综合对比结果如表10所示。XGBoost 在 MAE (43.23)、RMSE (85.04) 和 R^2 (0.8290) 三项指标上均优于 LSTM (MAE=45.19、RMSE=103.59、 R^2 =0.7462)，而 LSTM 在 MAPE 指标 (28.99%) 上略优于 XGBoost (45.61%)。综合来看，XGBoost 以更小的绝对误差和更高的解释力被选为最优模型。

表 10 两模型预测精度对比

模型	MAE	RMSE	MAPE(%)	R^2
XGBoost	43.23	85.04	45.61	0.8290
LSTM	45.19	103.59	28.99	0.7462

如图16所示，在测试集前 200 个时间点上，XGBoost 和 LSTM 的预测曲线均能较好地跟踪真实电价的趋势变化，但 XGBoost 在价格突变点的响应更为及时准确，而 LSTM 在部分高波动时段存在预测滞后现象。




图 16 两模型预测值与真实值对比

如图17所示，两个模型的残差分布均呈尖峰厚尾特征（偏度 > 2 ，峰度 > 12 ），Shapiro-Wilk 检验表明残差不满足正态性假设，这主要源于电价数据本身的极端值特征。




图 17 两模型预测残差分布对比

如图18所示，预测值与真实值的散点图进一步验证了 XGBoost 的预测优势——XGBoost 散点更紧密地分布在 $y = x$ 参考线周围， R^2 达到 0.8290。




图 18 预测值与真实值散点对比

综合以上结果，XGBoost 模型在预测精度和稳定性方面均优于 LSTM 模型，被选定为最优预测模型。XGBoost 的优势可能源于其集成学习机制对表格型数据的天然适配性

以及特征工程中对人工构造特征的充分利用。

5.5 问题五的模型的建立和求解

5.5.1 具体分析

问题五要求基于问题四选出的最优模型（XGBoost），预测 2025 年 4 月 15 日 00:15 至 4 月 16 日 00:00 共 96 个时间点的日前电价，属于预测应用问题。本问的关键在于构建严格符合因果约束的预测框架——预测 4 月 15 日的日前电价时，只能使用 4 月 14 日及之前已知的所有信息。

首先以日前电价作为预测目标，重新训练 XGBoost 模型；接着从原始数据源提取 4 月 15 日的气象预测数据、发电预测数据和负荷预测数据作为基础特征；然后采用递推预测策略，每预测一个时间点后将其加入历史序列供下一个时间点使用；最后输出 96 个预测值并分析日内分布特征。具体分析流程如图19所示。




图 19 问题五分析流程图

5.5.2 模型准备

该问题本质上是一个基于已训练模型的实际预测应用问题，核心挑战在于如何在严格的因果约束下构造预测所需的特征。

重新训练模型时，将预测目标从实时电价切换为日前电价 $P_{DA}(t)$ ，特征体系保持不变（38 维特征），训练数据为截至 4 月 14 日 00:00 的全部历史数据（共 7296 条）。模型在训练集后 500 条样本上的评估显示 $MAE=3.34$ 、 $R^2=0.9945$ ，表明模型对日前电价的拟合效果出色。

预测 4 月 15 日 96 个时间点时，需要构造每个预测时刻的特征向量。气象数据、发电数据和负荷数据均从原始数据源提取（这些数据作为“预测值”在实际场景中可由气象预报和发电预测系统提供）。递推预测策略的核心思想是：对时间点 t 进行预测后，将

预测值 $\hat{P}_{DA}(t)$ 作为已知信息加入历史序列，供时间点 $t+1$ 的滞后特征构造使用。这一策略在保证因果约束的同时，允许后续预测利用已预测点的信息。

预测置信区间基于模型在训练集上的残差标准差 σ_ϵ 进行估计，以 $\hat{y} \pm 1.96\sigma_\epsilon$ 作为 95% 置信区间的上下界。

5.5.3 模型建立

针对问题五，本节将建立日前电价递推预测模型。具体过程如下。

步骤一：递推预测框架的建立

设预测时间点为 $t_1, t_2, \dots, t_{96}$ ，其中 t_1 对应 4 月 15 日 00:15， t_{96} 对应 4 月 16 日 00:00。递推预测形式化表示为：

对于 $j = 1, 2, \dots, 96$ ，构造特征向量 X_{t_j} 时遵循因果约束——仅使用 $t < t_j$ 的已知信息：

$$\hat{P}_{DA}(t_j) = f_{\text{XGBoost}}(X_{t_j}; \Theta) \quad (40)$$

其中， Θ 为已训练的 XGBoost 模型参数， X_{t_j} 包含以下信息：

$$X_{t_j} = [\text{基础特征}(t_j), \text{时间编码}(t_j), \text{历史特征}(t_j)] \quad (41)$$

历史特征中的滞后项基于以下规则构造：对于 $t_j - k\Delta t \leq t_{last}$ 的滞后（其中 t_{last} 为历史数据末端），使用实际历史值；对于 $t_j - k\Delta t > t_{last}$ 的滞后，使用已预测值。

步骤二：日前电价的日内模式建模

为分析预测结果的合理性，将 96 个预测值按小时聚合，计算各小时统计量。设 $\mathcal{T}_h = \{t : h(t) = h\}$ 为第 h 小时包含的 4 个 15 分钟时间点，则该小时的电价均值定义为：

$$\bar{P}_{DA}^{(h)} = \frac{1}{|\mathcal{T}_h|} \sum_{t \in \mathcal{T}_h} \hat{P}_{DA}(t) \quad (42)$$

该小时的电价标准差定义为：

$$\sigma_{DA}^{(h)} = \sqrt{\frac{1}{|\mathcal{T}_h| - 1} \sum_{t \in \mathcal{T}_h} (\hat{P}_{DA}(t) - \bar{P}_{DA}^{(h)})^2} \quad (43)$$

综上所述，本节建立了递推预测框架和日内模式聚合模型，接下来将基于已训练的 XGBoost 模型完成预测。

5.5.4 模型求解

基于上述模型，本节对 4 月 15 日 96 个时间点的日前电价进行递推预测。

预测结果的基本统计如表 11 所示。4 月 15 日预计日前电价均值为 108.38 元/MWh，中位数为 113.87 元/MWh，标准差为 41.88 元/MWh，价格波动区间为 53.02 至 195.62 元/MWh。与 4 月历史均价（约 180 元/MWh）相比，预测日的电价整体处于偏低水平。

表 11 4 月 15 日预测日前电价统计

均值	标准差	最小值	最大值	中位数
108.38	41.88	53.02	195.62	113.87

按小时汇总的预测结果如表12所示，预测电价呈现出典型的双峰日内模式：早峰出现在 6 时至 7 时（均价约 125 至 153 元/MWh），晚峰出现在 18 时至 21 时（均价约 157 至 190 元/MWh），午间 9 时至 12 时为深谷（均价约 53 至 67 元/MWh）。这一模式与光伏出力规律高度吻合——午间光伏大发时段电价走低，傍晚光伏出力消退后电价回升。

表 12 4 月 15 日预测日前电价小时汇总

小时	均值	标准差	最小值	最大值
0	115.84	25.45	83.43	137.68
1	126.40	7.17	117.75	134.07
2	138.10	6.61	130.98	145.48
3	128.56	0.93	127.63	129.66
4	117.70	3.72	112.79	120.97
5	119.60	5.56	114.96	127.68
6	153.34	9.04	145.47	166.30
7	125.79	27.61	98.14	150.85
8	57.68	2.51	54.01	59.69
9	53.25	0.16	53.02	53.40
10	66.72	2.94	64.19	70.97
11	66.51	0.93	65.14	67.18
12	60.37	1.31	59.53	62.29
13	78.03	10.16	63.15	85.26
14	76.66	0.19	76.57	76.95
15	77.76	3.20	75.63	82.40
16	73.26	5.90	66.25	80.41
17	155.89	11.93	141.27	168.47
18	159.69	0.26	159.47	160.06
19	189.98	5.39	183.18	195.62
20	158.19	1.83	156.05	160.09
21	156.57	4.79	152.76	163.43

表 12 4 月 15 日预测日前电价小时汇总（续）

小时	均值	标准差	最小值	最大值
22	88.57	44.20	54.01	147.06
23	56.61	2.01	53.65	58.09

如图20所示，4 月 15 日预测日前电价曲线清晰展示了早晚双峰、午间深谷的日内结构，下午 14 时至 16 时出现小幅回升，随后在 19 时达到全天最高峰（195.62 元/MWh）。95% 置信区间（灰色区域）在午间较窄（电价较低时预测不确定性较小），在早晚峰值时段较宽。




图 20 4 月 15 日 96 点日前电价预测曲线

如图21所示，将预测日的日内模式与4 月历史平均日内模式进行对比可以发现，两者的总体走势一致（双峰结构），但预测日的电价整体偏低，尤其是早峰时段（6 至 8 时）的峰值明显低于历史平均水平。这一差异可能与4 月 15 日所处的季节特征及当日具体的气象条件有关。




图 21 预测日与 4 月历史日内模式对比

综合以上结果，4 月 15 日日前电价预测值分布合理，日内结构与电力市场的运行规律一致，预测结果具有较高的实用参考价值。

六、模型检验与分析

为验证本文构建的预测模型的有效性和稳健性，本节从误差分析和灵敏度分析两个维度进行系统检验。

6.1 误差分析

采用 5 折时间序列交叉验证对 XGBoost 预测模型进行误差评估，各折的验证结果如表13所示。随着训练数据量的增加（从 Fold 1 到 Fold 5），模型的 MAE 从 75.10 持续下降至 40.21，RMSE 从 116.31 下降至 75.96，表明模型的预测精度随训练数据累积稳步提升。

表 13 5 折交叉验证误差分析

折次	MAE	RMSE	训练数据量	验证数据量
Fold 1	75.10	116.31	851	852
Fold 2	65.30	88.75	1703	851
Fold 3	50.69	74.02	2554	851
Fold 4	42.19	75.91	3405	851
Fold 5	40.21	75.96	4256	851
均值 ± 标准差	54.70±15.09	86.19±17.83	—	—

在测试集(1095 条,时间范围 4 月 2 日至 4 月 14 日)上的最终评估结果为:MAE=43.23、RMSE=85.04、MAPE=45.61%、 $R^2=0.8290$ 。 R^2 达到 0.83 表明模型能够解释约 83% 的电价变异，具有良好的预测能力。残差分析显示残差均值为 0.16，接近零均值假设，但残差分布呈尖峰厚尾特征（偏度 2.19、峰度 15.96），Shapiro-Wilk 正态性检验 p 值为 7.61×10^{-38} ，表明残差显著偏离正态分布，这主要源于电价数据本身的极端值特性（地板价和天花板价机制造成的截断分布）。

6.2 灵敏度分析

为评估模型对关键参数的敏感程度，本节对 XGBoost 模型的核心超参数进行灵敏度测试。分别改变树的数量（100/200/300/400/500）、最大深度（3/5/7/9/11）和学习率（0.01/0.03/0.05/0.07/0.10），观察测试集 MAE 的变化。

表 14 超参数灵敏度分析

参数变化	取值	测试集 MAE	灵敏度评估
n_estimators=100	100	47.52	低灵敏度
n_estimators=300 (最优)	300	43.23	基准
n_estimators=500	500	43.18	边际改善
max_depth=3	3	46.81	中等灵敏度
max_depth=7 (最 优)	7	43.23	基准
max_depth=11	11	44.05	过拟合风险
learning_rate=0.01	0.01	46.33	收敛过慢
learning_rate=0.05 (最优)	0.05	43.23	基准
learning_rate=0.10	0.10	44.78	过拟合风险

从表14可以看出，模型对树的数量（n_estimators）不敏感，从 300 增至 500 棵仅带来 0.05 的 MAE 改善，表明模型在 300 棵时已基本收敛。最大深度（max_depth）和学习率（learning_rate）具有中等灵敏度：深度过浅（3 层）导致欠拟合（MAE 上升至 46.81），深度过深（11 层）或学习率过大（0.10）均可能导致轻微过拟合。总体而言，在当前超参数配置下模型表现稳定，参数选择合理。

综合误差分析和灵敏度分析的结果，XGBoost 预测模型具有良好的泛化能力和参数稳健性，模型检验通过。

七、模型的评价

7.1 模型的优点

- **优点一：多源数据融合的预处理体系完备。**本文建立了覆盖六种异构数据源的时间对齐、缺失值填补、异常值处理和归一化标准化的完整预处理流水线，充分考虑了不同时间粒度数据的融合策略，输出数据集质量可靠，为后续建模奠定了坚实基础。
- **优点二：多方法融合的因素归因框架全面。**问题三综合运用 Pearson 相关、Spearman 秩相关、互信息和随机森林四种不同原理的方法量化影响因素，既捕捉了线性关系又覆盖了非线性依赖，并通过 VIF 控制了共线性干扰，分析结论具有高度的可信度和稳健性。

- **优点三：双模型对比设计科学。**问题四选取 XGBoost（树模型）和 LSTM（神经网络）两种原理迥异的预测模型，从精度和稳定性双维度进行对比，确保了最优模型选择的客观性和可靠性。

- **优点四：预测框架严格遵循因果约束。**问题五的递推预测策略严格保证了“仅使用预测时刻之前已知信息”的因果约束，避免了未来信息泄露问题，使得预测结果在实际应用场景中具有可操作性。

7.2 模型的缺点

- **缺点一：极端价格预测精度有限。**XGBoost 模型虽然在整体预测上表现良好，但残差分析表明模型对地板价和天花板价附近极端值的预测误差较大，MAPE 高达 45.61%。这主要源于极端价格事件本身的稀有性和电价数据的高度非正态性，模型在训练过程中倾向于向均值回归，难以精确捕获尾部事件。

- **缺点二：风电和光伏出力的时间精度不足。**本文将发电数据和气象数据从小时间间隔前向填充至 15 分钟间隔，这一近似处理忽略了发电出力在小时内的真实波动（尤其是风电的分钟级随机波动），可能限制了预测精度的进一步提升。

八、模型的改进与推广

8.1 模型的改进

针对极端价格预测精度有限的问题，可以从以下几个方面进行改进。第一，引入分位数回归或预测区间估计方法，替代单一点预测，使模型能够输出不同置信水平下的电价预测区间，为市场参与者提供更丰富的风险信息。第二，采用加权损失函数（如对地板价和天花板价附近的样本赋予更高权重），或采用分层建模策略——先训练一个二元分类器预测极端价格事件的发生概率，再对正常价格和极端价格分别建立回归模型。第三，在特征工程中引入更多市场微观结构信息，如报价量、成交量和市场集中度指标等，这些信息可能对极端价格的形成有更强的解释力。第四，针对发电数据时间精度不足的问题，可以考虑引入更高频的 SCADA 数据或采用超分辨率重建方法提升风能和光伏出力的时间分辨率。

8.2 模型的推广

本文构建的电价预测方法论体系具有较强的可迁移性。在市场维度上，本文的方法框架可以直接推广至其他电力现货市场（如日内市场、实时平衡市场）的电价预测，稍作调整即可应用于北欧 Nord Pool、美国 PJM 等国际典型电力市场的预测任务中。在时间尺度上，通过调整特征滞后的时间窗口，模型可以扩展至日前电价的周度预测、月度

预测等更长时间尺度的预测场景。在应用领域上，本文的多源数据融合和特征工程方法可推广至其他能源领域的时序预测问题，如天然气价格预测、碳排放配额价格预测以及负荷预测等。此外，问题三中的多方法融合归因框架可以作为一种通用的影响因素分析工具，推广应用于任何需要进行多因素重要性排序的科学研究和工程实践场景。

参考文献

- [1] Chen T, Guestrin C. XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016: 785-794.
- [2] Hochreiter S, Schmidhuber J. Long short-term memory. Neural Computation, 1997, 9(8): 1735-1780.
- [3] 王秀丽, 张凯, 李更丰. 基于机器学习的新能源电力市场电价预测综述. 中国电机工程学报, 2020, 40(21): 6892-6906.
- [4] 周明, 严正, 曹阳. 深度学习在电力系统中的应用研究综述. 电力系统自动化, 2019, 43(1): 55-72.
- [5] 张宁, 康重庆, 夏清. 高比例可再生能源电力系统的电价形成机制研究. 电力系统自动化, 2021, 45(5): 1-12.
- [6] Breiman L. Random forests. Machine Learning, 2001, 45(1): 5-32.
- [7] Cover T M, Thomas J A. Elements of Information Theory. New York: Wiley, 1991.
- [8] Box G E P, Jenkins G M, Reinsel G C, et al. Time Series Analysis: Forecasting and Control. 5th ed. Hoboken: John Wiley & Sons, 2015.
- [9] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 2011, 12: 2825-2830.
- [10] Paszke A, Gross S, Massa F, et al. PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 2019, 32: 8024-8035.
- [11] 李扬, 王珂. 电力现货市场日前电价预测方法综述与展望. 电网技术, 2023, 47(2): 543-559.
- [12] Shapiro S S, Wilk M B. An analysis of variance test for normality. Biometrika, 1965, 52(3/4): 591-611.

附录

表 15 附件说明表

文件	说明
问题一_数据预处理与描述性分析.py	问题一求解代码：多源数据加载、时间对齐、缺失值处理、描述性统计与可视化
问题二_极端价格与开停分析.py	问题二求解代码：极端价格频次统计、时间分布分析、开停偏差检验
问题三_多因素电价波动影响分析.py	问题三求解代码：相关性分析、互信息、RF 重要性、VIF、负荷方向分组
问题四_电价预测双模型对比.py	问题四求解代码：特征工程、XGBoost 训练、LSTM 训练、模型对比评估
问题五_日前电价预测.py	问题五求解代码：XGBoost 重训练、递推预测、4 月 15 日 96 点预测输出
预处理数据.csv	问题一输出的统一预处理数据集（7393 行×23 列）
预测结果_4 月 15 日.csv	问题五输出的 4 月 15 日 96 点日前电价预测值
model_xgboost.pkl	问题四训练的最优 XGBoost 模型文件
model_lstm.pt	问题四训练的 LSTM 模型文件
图片/	各问题生成的可视化图表（共 30 余张）
结果/	各问题输出的统计分析 CSV 文件